



**TIBBİ GÖRÜNTÜLEMEDE YAPAY ZEKA UYGULAMALARI
DERS PROJESİ**

DEEPEMBRYO: 5. GÜN EMBRİYO KALİTE DEĞERLENDİRME SİSTEMİ

Doç. Dr. YILDIRAY ANAGÜN

Grup Üyeleri:

Şevval Ayça Çerence - 152120211128

Nisanur Pehlivan - 152120221054

Merve Selçuk - 152120211116

Pelin Özer - 152120231100

2025-2026

İçindekiler

1. Giriş, Problem Tanımı ve Klinik Arka Plan	3
1.1 Projenin Çıkış Noktası	3
1.2 Klinik Kavramlar: Blastosist, ICM ve TE.....	3
1.3 Projenin Başarı Tanımı	4
2. İsterlerin Karşılama Özeti	5
3. Veri Seti ve Etiketleme Yapısı.....	5
4. Veri Ön İşleme ve Bölme Süreci	6
5. Model Gelişim Süreci	7
6. Nihai Model Mimarisi ve ResNet50 Gerekçesi	7
6.1 Neden ResNet50 Seçildi?.....	8
6.2 Alternatif Mimariler ve Tercih Nedeni	9
6.3 Modelin Klinik Yorumlanabilirliği	9
7. Hiperparametreler ve Eğitim Süreci	10
8. Analiz Çıktıları ve Metrikler.....	11
8.1 Genel Test Performansı	11
8.2 Precision, Recall ve F1-Score	12
8.3 Confusion Matrix Yorumu	12
8.4 Ek Grafikler: Learning Curve ve Sınıf Performansı	13
8.5 XAI: Grad-CAM Çıktıları.....	14
9. Uygulama, Raporlama ve Veritabanı.....	15
9.1 Veritabanı Durumu.....	16
9.2 Uygulama Ekran Görüntüleri	16
10. Kritik Bulgular ve İyileştirme Önerileri	19
11.Kaynakça.....	20

1. Giriş, Problem Tanımı ve Klinik Arka Plan

1.1 Projenin Çıkış Noktası

DeepEmbryo projesi, tüp bebek (IVF) laboratuvarlarında 5. gün blastosist embriyolarının kalite değerlendirmesini yapay zeka ile desteklemek amacıyla geliştirilmiştir. Klinik pratikte embriyo kalitesi çoğunlukla embriyologların mikroskop görüntülerini görsel olarak incelemesiyle belirlenir. Bu değerlendirme uzmanlık gerektirir; ancak aynı görüntünün farklı uzmanlar tarafından farklı yorumlanabilmesi, yoğun iş akışında yorgunluğa bağlı karar değişkenliği ve değerlendirme süresinin uzaması gibi problemler taşır. Sunumda da vurgulanan ana hedef, embriyologun kararını değiştirmek değil, ona standart, hızlı ve açıklanabilir bir ikinci görüş sağlamaktır.

Bu nedenle proje yalnızca bir sınıflandırma modeli olarak değil, model çıktısının klinik kullanıcıya anlaşılır biçimde sunulduğu uçtan uca bir karar destek prototipi olarak ele alınmıştır. Son ürün; eğitim kodu, analiz çıktıları, açıklanabilir yapay zeka görselleri, PyQt5 masaüstü arayüzü, PDF raporlama ve SQLite tabanlı geçmiş/ground truth kaydı bileşenlerinden oluşur.

Embriyo kalite değerlendirmesi yüksek uzmanlık gerektiren, görsel ayrıntılara duyarlı ve doğal olarak subjektif bir süreçtir. DeepEmbryo bu süreci otomatikleştirirken klinik güvenlik için tahmin güven skorunu, manuel kontrol uyarısını ve Grad-CAM açıklamasını birlikte verir.

1.2 Klinik Kavramlar: Blastosist, ICM ve TE

5. gün embriyosu genellikle blastosist evresinde değerlendirilir. Gardner sınıflandırma sistemi, blastosistin genişleme derecesini ve iki temel morfolojik yapının kalitesini birlikte ele alır. İlk harf ICM, yani İç Hücre Kütleli kalitesini; ikinci harf TE, yani Trofektoderm kalitesini temsil eder. ICM ileride embriyonun bebek dokularına dönüşecek hücre grubuyla ilişkilidir. TE ise plasenta ve embriyonun rahme tutunmasıyla ilişkili dış hücre tabakasını temsil eder.

Tablo 1A. Klinik morfoloji kavramları ve modeldeki karşılığı

Klinik kavram	Anlamı	Model açısından önemi
ICM	İç Hücre Kütleli; bebeğe dönüşecek hücre grubu	Merkez veya kenarda yoğun hücre dokusu olarak görülebilir; Grad-CAM ile odak kontrolü yapılır
TE	Trofektoderm; dış halka ve plasenta ilişkili hücre tabakası	Dış çeper düzeni ve hücre yoğunluğu kalite kararında önemlidir
Gardner harfleri	AA, AB, BA, BB, BC, CB, CC, CA, AC	Good/Fair/Poor klinik sınıflarına dönüştürülen temel etiket bilgisidir
Genişleme derecesi	3, 4 vb. sayısal blastosist evresi	Bu projede ana klinik sınıf kararında harf kombinasyonları öne çıkarılmıştır

Bu klinik çerçeve, model tasarımındaki en önemli kararı açıklar: V1'deki 13 sınıflı doğrudan Gardner tahmini, veri azlığı nedeniyle güvenilir sonuç vermemiştir. Bunun yerine nihai V2.1 modelinde Gardner harf kombinasyonları klinik karar diline daha yakın Good, Fair ve Poor sınıflarına gruplanmıştır.

1.3 Projenin Başarı Tanımı

Bu rapordaki başarı, yalnızca yüksek accuracy değeriyle tanımlanmamıştır. Tıbbi karar destek sistemlerinde modelin hangi sınıfı ne ölçüde yakaladığı, yanlış sınıflandırmanın klinik etkisi, güven skoru, açıklanabilirlik ve kullanıcıya sunum biçimi birlikte değerlendirilmelidir. DeepEmbryo için özellikle Good sınıfı recall değeri, transfer adayı embriyoların kaçırılmaması açısından önemlidir. Poor sınıfındaki düşük performans ise modelin klinik güvenlik sınırını gösteren en açık geliştirme alanıdır.

Tablo 1B. Proje başarı ölçütleri

Başarı boyutu	Raporda nasıl ölçüldü?	Mevcut durum
Sınıflandırma başarımı	Accuracy, precision, recall, F1-score	Test accuracy %68.18; Good recall %93
Sınıf güvenliği	Confusion Matrix ve sınıf bazlı recall	Poor recall 0.00; klinik risk olarak işaretlendi
Öğrenme davranışı	Accuracy-Loss ve eğitim logları	Val accuracy en iyi %71.4; val loss en düşük 0.0828
Açıklanabilirlik	Grad-CAM ve SHAP çıktıları	ICM/TE odak kontrolü için görsel kanıt üretildi
Klinik kullanım prototipi	PyQt5 arayüz, PDF rapor, SQLite kayıt	Tekli/batch analiz ve ground truth döngüsü mevcut

2. İsterlerin Karşılama Özeti

Tablo 2, her gereksinimin hangi proje dosyasıyla ve hangi rapor bölümüyle desteklendiğini gösterir.

Tablo 2. İster-dosya-rapor eşleştirilmesi

Gereksinim	Kanıt / Dosya	Rapordaki yer
Veri seti açıklaması	EMBRIO GRADE DATASET, data_pipeline.py	Bölüm 3-4
Model mimarisi	train_clinical_model.py, model_architecture.py, pytorch_model.py	Bölüm 5-6
Hiperparametreler	train_clinical_model.py, clinical_refined_training_log.csv	Bölüm 7
Eğitim süreci	clinical_training_log.csv, clinical_refined_training_log.csv	Bölüm 7
Accuracy-Loss grafiği	results/accuracy_loss_curves.png	Bölüm 8, Şekil 1
Confusion Matrix	results/confusion_matrix.png	Bölüm 8, Şekil 2
Precision / Recall	results/classification_report.txt, classification_report.csv	Bölüm 8, Tablo 15
XAI / Grad-CAM	results/gradcam_results.png, xai_results/gradcam_samples	Bölüm 8-9, Şekil 5
Uygulama çıktıları	DeepEmbryo_App/main.py, ui_main.py, ui_report.py, database.py	Bölüm 9-10

3. Veri Seti ve Etiketleme Yapısı

Ham veri seti EMBRIO GRADE DATASET klasöründe BMP formatındaki mikroskop görüntülerinden oluşur. Sunumda ve analiz dokümanlarında veri kaynağı, time-lapse inkübatör veya mikroskopik embriyo görüntüsü olarak anlatılmıştır. Mevcut çalışma klasöründe sayılan ham dosya toplamı 170 görüntüdür. Bunların 141 tanesi blastosist niteliğindeki Gardner etiketleriyle V2 klinik modele alınmış, 29 adet Cleavage görüntüsü nihai klinik 5. gün transfer sınıflandırmasına dahil edilmemiştir.

Tablo 3. Ham veri klasör dağılımı

Ham klasör	Görüntü sayısı	Açıklama
3AA	40	Klasör içinde 3AA, 3AB ve 3BA varyantları bulunur
3CC	40	Klasör içinde 3BB, 3BC, 3CA, 3CB, 3CC varyantları bulunur
4AA	61	Klasör içinde 4AA, 4AB, 4BA, 4BB varyantları bulunur
Cleavage	29	5. gün blastosist kararı dışında bırakılan erken evre örnekler
Toplam	170	Ham veri toplamı

Kritik veri temizleme kararı dosya adından Gardner harf çiftini okumaktır. data_pipeline.py içinde AA, AB, BA kombinasyonları Good; BB, BC, CB kombinasyonları Fair; CC, CA, AC kombinasyonları Poor olarak gruplanmıştır. Bu karar, V1'deki 13 sınıflı parçalı etiketleri klinik açıdan yorumlanabilir üç transfer kalitesi grubuna dönüştürür.

Tablo 4. Klinik sınıf dönüştürme mantığı

Klinik sınıf	Gardner harfleri	Klinik yorum	Toplam
Good	AA, AB, BA	Transfer için öncelikli aday; ICM/TE kalitesi güçlü	98
Fair	BB, BC, CB	Transfer edilebilir veya dondurulabilir orta kalite	20
Poor	CC, CA, AC	Düşük kalite; klinik karar için dikkat gerektirir	23
Toplam	-	Cleavage hariç klinik blastosist toplamı	141

Veri seti sınırlılığı

V2 modelinde Good sınıfı 98 örnekle baskındır. Fair 20, Poor 23 örnekle çok daha küçüktür. Bu dengesizlik, özellikle Poor sınıfında recall değerinin sıfır kalmasını açıklayan ana etkenlerden biridir.

4. Veri Ön İşleme ve Bölme Süreci

data_pipeline.py önce blastosist görüntülerini klinik sınıflara yeniden kopyalar, ardından stratified train/validation/test bölmesi yapar. Bölme oranı %70 eğitim, %15 doğrulama ve %15 testtir. Stratified bölme seçimi, her sette Fair, Good ve Poor sınıflarından örnek kalmasını sağlar.

Tablo 5. Klinik veri split dağılımı

Set	Fair	Good	Poor	Toplam	Oran
Train	14	68	16	98	%69.5
Validation	3	15	3	21	%14.9
Test	3	15	4	22	%15.6
Toplam	20	98	23	141	%100

Tablo 6. Eğitim hattındaki ön işleme ve augmentation adımları

Ön işleme adımı	Kod karşılığı	Amaç
Resize	target_size=(224, 224)	ResNet50 giriş boyutuna standardizasyon
Piksel ölçekleme	rescale=1./255	Eğitimde değerleri [0, 1] aralığına çekme
Yatay/dikey flip	horizontal_flip=True, vertical_flip=True	Az veride görünüm çeşitliliği sağlama
Rotasyon	rotation_range=15	Embriyo yönlenmesine duyarsızlık kazandırma
Parlaklık	brightness_range=[0.9, 1.1]	Mikroskop aydınlatma farklarına

Ön işleme adımı	Kod karşılığı	Amaç
		dayanıklılık
Manual oversampling	Azınlık sınıfları max_count seviyesine kopyalama	Good baskınlığını eğitim sırasında azaltma
Val/Test	Sadece rescale	Değerlendirmede veri artırımı kullanmama

5. Model Gelişim Süreci

Kodlar ve raporlar üç aşamalı bir mühendislik karar zinciri gösterir. V1'de 13 sınıflı Gardner etiketleri doğrudan öğrenilmeye çalışılmıştır. Sonuçlar düşük kalınca PyTorch ile üç sınıflı morfolojik model denenmiş, son aşamada ise klinik karar ile daha uyumlu TensorFlow/Keras modeli üretilmiştir.

Tablo 7. Model geliştirme evrimi

Aşama	Sınıf yapısı	Dosyalar	Temel sonuç / karar
V1	13 sınıf: 12 Gardner + Cleavage	v1_12_classes_experiments	Sınıf başına veri azlığı nedeniyle başarısız; test accuracy %0-%20
Ara faz	High Quality, Low Quality, Cleavage	DeepEmbryo_Colab_Trainin g.py, pytorch_model.py	Weighted loss ve sınıfa özel augmentation ile düşük kalite recall artırılmaya çalışıldı
V2.1	Fair, Good, Poor	v2_3_classes_clinical_model	Klinik transfer edilebilirlik mantığına geçildi; Good recall %93

Tablo 8. V1 deney sonuçları ve sınıf sayısını azaltma gerekçesi

V1 deney	Best epoch	Train Acc	Val Acc	Test Acc	Test Loss
Exp1 Baseline	1	%2.5	%20.0	%20.0	2.515
Exp1 Baseline tekrar	6	%13.3	%16.0	%16.0	2.430
Exp2 Heavy Augmentation	1	%2.5	%4.0	%0.0	2.575
Exp3 High Regularization	4	%12.5	%16.0	%16.0	5.490

6. Nihai Model Mimarisi ve ResNet50 Gerekçesi

Nihai model train_clinical_model.py içinde Functional API ile tanımlanmıştır. Giriş katmanı 224 x 224 x 3 RGB embriyo görüntüsüdür. Omurga ResNet50'dir ve ImageNet ağırlıkları kullanılır. Kod önce ../resnet50_weights.h5 dosyasını arar; yoksa Keras'ın imagenet ağırlığına düşer. İlk 143 katman dondurulur, daha üst konvolüsyon blokları fine-tuning için açık bırakılır.

Tablo 9. Nihai TensorFlow/Keras model mimarisi

Katman / blok	Çıktı	Parametre / rol
Input	224 x 224 x 3	RGB embriyo görüntüsü
ResNet50 include_top=False	7 x 7 x 2048	Transfer learning omurgası, yaklaşık 23.6M parametre
GlobalAveragePooling2D	2048	Uzamsal özellikleri vektöre indirger
Dropout	2048	rate=0.6; overfitting azaltma
Dense	256	ReLU aktivasyonlu klinik özellik katmanı
BatchNormalization	256	Aktivasyon dağılımını stabilize eder
Dropout	256	rate=0.5; ikinci regularization katmanı
Dense clinical_output	3	Softmax; Fair, Good, Poor olasılıkları

ResNet50 omurgası ve özel sınıflandırıcı başlığı birlikte yaklaşık 24.1 milyon parametre içerir. Bu büyüklük küçük veri için riskli olduğundan dropout, batch normalization, düşük learning rate, focal loss ve erken durdurma birlikte kullanılmıştır.

6.1 Neden ResNet50 Seçildi?

ResNet50 seçimi dört temel gerekçeyle açıklanmıştır: sınırlı veriyle transfer learning avantajı, mikroskobik ayrıntılara duyarlı residual block yapısı, tıbbi görüntüleme literatüründe yaygın ve güvenilir bir CNN omurgası olması, ayrıca Grad-CAM gibi açıklanabilirlik yöntemleriyle uyumlu son konvolüsyon katmanları sunması. Bu gerekçeler, projenin veri ve klinik şeffaflık ihtiyaçlarıyla doğrudan örtüşmektedir.

ResNet50'nin residual bağlantıları, derin ağlarda görülen gradyan sönmesi problemini azaltır. Bu yapı sayesinde model, embriyo görüntüsündeki çok ince ICM/TE dokusu farklarını derin katmanlara taşıırken erken katmanlarda öğrenilen kenar, doku ve kontrast bilgisini kaybetmez. Embriyo görüntüleri birbirine çok benzeyen, küçük morfolojik ayrıntılarla ayrışan görüntüler olduğu için bu özellik projede özellikle değerlidir.

Tablo 10. ResNet50 seçiminin teknik ve klinik gerekçeleri

Seçim kriteri	ResNet50'nin sağladığı avantaj	DeepEmbryo için etkisi
Transfer learning	ImageNet üzerinde ön öğrenilmiş düşük/orta seviye görsel filtreler	141 klinik blastosist görüntüsüyle sıfırdan eğitim riskini azaltır
Residual block	Kimlik bağlantılarıyla derin ağda bilgi akışını korur	ICM/TE gibi ince doku farklarının kaybolmasını azaltır
Optimum derinlik	50 katman; güçlü ama prototip için yönetilebilir	Eğitim süresi, model kapasitesi ve uygulama entegrasyonu dengelenir
224x224 uyumu	Standart ResNet giriş hattı	İsterde belirtilen 224x224 ön işleme gereksinimiyle doğrudan uyumludur
Grad-CAM uyumu	conv5_block3_out gibi son konvolüsyon katmanları bulunur	Model kararının ICM/TE veya dış çeper odağı görselleştirilebilir
Literatür standardı	Tıbbi görüntü sınıflandırmada sık kullanılan CNN omurgası	Teknik değerlendirme için açıklanabilir, tanıdık bir tercih sunar

6.2 Alternatif Mimariler ve Tercih Nedeni

İster dokümanında CNN tabanlı mimariler, EfficientNetB0 ve InceptionV3 gibi transfer learning seçenekleri uygun alternatifler olarak görülmektedir. Bu projede ResNet50'nin seçilmesi, en yüksek teorik performans iddiasından çok, küçük veri setinde güvenilir başlangıç noktası sağlaması ve açıklanabilirlik boru hattının kolay kurulabilmesi nedeniyledir. EfficientNet daha parametre-verimli olabilir; Inception farklı ölçeklerde özellik çıkarabilir. Ancak ResNet50, hem eğitim kodunda hem masaüstü uygulamasında hem de Grad-CAM analizinde daha yalın ve denetlenebilir bir mühendislik zemini sağlamıştır.

Tablo 11. Alternatif mimariler ve ResNet50 tercih gerekçesi

Mimari	Güçlü tarafı	Bu projede tercih durumu
ResNet50	Residual block, transfer learning, Grad-CAM uyumu	Nihai omurga olarak seçildi
EfficientNetB0	Parametre verimliliği ve modern ölçekleme	Gelecek karşılaştırmalı deney için uygun
InceptionV3	Çok ölçekli özellik çıkarımı	299x299 giriş ve daha karmaşık hat nedeniyle kullanılmadı
Vision Transformer	Büyük veriyle güçlü global dikkat	Veri sayısı çok az olduğu için riskli görüldü
Sıfırdan CNN	Tam kontrol ve küçük model	Küçük veride overfitting ve zayıf genelleme riski yüksek

6.3 Modelin Klinik Yorumlanabilirliği

ResNet50 seçimi yalnızca sınıflandırma başarımları için değil, kararın açıklanabilmesi için de önemlidir. Grad-CAM, son konvolüsyon katmanındaki aktivasyonları hedef sınıf gradyanlarıyla ağırlıklandırarak modelin görüntüde hangi bölgeyi kullandığını gösterir. Bu projede beklenen klinik davranış, modelin arka plan veya boş petri alanı yerine embriyonun ICM ve TE ile ilişkili hücre bölgelerine odaklanmasıdır. Bu nedenle raporda Grad-CAM görselleri yalnızca süsleyici çıktı değil, modelin klinik olarak anlamlı morfolojik işaretlere bakıp bakmadığını sorgulayan temel analiz çıktısıdır.

ResNet50, küçük veri setinde sıfırdan öğrenmeye çalışmak yerine önceden öğrenilmiş görsel bilgiyi embriyo morfolojisine uyarladığı için seçildi. Residual bloklar ince doku bilgisinin ağ içinde kaybolmasını azaltırken, son konvolüsyon katmanları Grad-CAM ile modelin ICM/TE bölgelerine bakıp bakmadığını göstermemizi sağladı.

7. Hiperparametreler ve Eğitim Süreci

Tablo 12. Nihai model hiperparametreleri


Hiperparametre	Değer	Kod kanıtı
Framework	TensorFlow / Keras	train_clinical_model.py
Mimari	ResNet50 + custom head	build_functional_model()
Görüntü boyutu	224 x 224	IMG_SIZE=(224,224)
Batch size	8	BATCH_SIZE=8
Epoch üst sınırı	50	EPOCHS=50; EarlyStopping 26 epoch civarında durdurdu
Optimizer	AdamW	learning_rate=1e-5, weight_decay=1e-2
Loss	FocalLoss	gamma=2.0, alpha=0.25
Metrikler	Accuracy, Precision, Recall	model.compile(metrics=[...])
EarlyStopping	patience=15	monitor=val_loss, restore_best_weights=True
LR scheduler	ReduceLROnPlateau	factor=0.5, patience=5, min_lr=1e-8
Checkpoint	best_clinical_model_v2_1.h5	monitor=val_loss, save_best_only=True
Logger	clinical_refined_training_log.csv	Epoch bazlı CSV kayıt

Refined eğitim günlüğü 26 satır içerir. En düşük validation loss epoch 10 değerinde 0.0828 olarak kaydedilmiştir. En yüksek validation accuracy epoch 10 değerinde %71.4 seviyesindedir. Son epoch sonunda validation accuracy %61.9, validation recall %42.9 ve validation precision %64.3'tür.

Tablo 13. Refined eğitim sürecinden seçili epoch değerleri

Epoch	Train Acc	Train Loss	Val Acc	Val Loss	Val Precision	Val Recall	LR
0	%29.4	0.385	%14.3	0.224	%0.0	%0.0	1e-05
5	%38.2	0.366	%14.3	0.162	%14.3	%9.5	1e-05
10	%32.4	0.356	%71.4	0.083	%66.7	%9.5	1e-05
15	%39.2	0.351	%66.7	0.095	%57.1	%19.0	1e-05
20	%37.3	0.330	%71.4	0.088	%66.7	%47.6	5e-06
25	%44.1	0.315	%61.9	0.095	%64.3	%42.9	2.5e-06

Eğitim eğrisi üç önemli davranış gösterir. İlk olarak validation loss epoch 0'dan 10'a kadar düzenli düşmüştür; bu modelin klinik sınıf ayrımını öğrenmeye başladığını gösterir. İkinci olarak validation accuracy epoch 8-10 aralığında hızlı yükselmiş ve %71.4'e ulaşmıştır. Üçüncü olarak epoch 10 sonrasında validation loss dalgalanmış, bu nedenle ReduceLROnPlateau learning rate'i önce 5e-6'ya, sonra 2.5e-6'ya indirmiştir. Şekil 1'deki Accuracy-Loss grafiğinde bu davranış net biçimde görülmektedir.



Şekil 1. Accuracy-Loss eğitim ve validasyon eğrileri

8. Analiz Çıktıları ve Metrikler

8.1 Genel Test Performansı

Tablo 14. Test sonuçları özeti

Metrik	Değer	Yorum
Test accuracy	%68.18	22 test görüntüsünden 15 doğru tahmin
Macro F1	0.40	Sınıf başına eşit ağırlıklı ortalama; Poor başarısızlığı nedeniyle düşük
Weighted F1	0.60	Good sınıfının test desteği yüksek olduğu için macro ortalamadan daha iyi
Good F1	0.80	Klinik seçilebilir embriyoyu yakalama açısından en güçlü sonuç
Fair F1	0.40	Orta kalite sınıfında veri azlığı nedeniyle sınırlı
Poor F1	0.00	Model bu test setinde Poor sınıfını yakalayamamıştır

8.2 Precision, Recall ve F1-Score

classification_report.txt dosyası Fair, Good ve Poor sınıfları için precision, recall, f1-score ve support değerlerini verir. Klinik yorum açısından Good recall değeri özellikle önemlidir; model test setindeki 15 Good örneğin 14'ünü doğru yakalamıştır.

Tablo 15. Sınıf bazlı precision, recall ve f1-score


Sınıf	Precision	Recall	F1-score	Support	Klinik yorum
Fair	0.50	0.33	0.40	3	3 Fair örnekten 1'i doğru; orta kalite sınırı netleşmeli
Good	0.70	0.93	0.80	15	15 Good örnekten 14'ü doğru; transfer adayı yakalamada güçlü
Poor	0.00	0.00	0.00	4	4 Poor örnekten hiçbiri doğru yakalanmadı; kritik risk
Accuracy	-	-	0.68	22	Genel doğruluk %68.18
Macro avg	0.40	0.42	0.40	22	Sınıflar arası dengesizliğin etkisini gösterir
Weighted avg	0.55	0.68	0.60	22	Good ağırlığı nedeniyle daha yüksek

8.3 Confusion Matrix Yorumu

Confusion matrix, rapordaki en kritik analiz çıktılarından biridir. classification_report değerlerinden türeyen tutarlı ham matris Tablo 16'da verilmiştir: Fair sınıfında 1 doğru ve 2 Good tahmini, Good sınıfında 14 doğru ve 1 Fair tahmini, Poor sınıfında ise 4 örneğin tamamı Good'a kaymıştır. Bu nedenle model iyi embriyoyu kaçırmama konusunda güçlü, kötü embriyoyu ayırma konusunda zayıftır.

Tablo 16. Confusion matrix ham sayı yorumu


Gerçek \ Tahmin	Fair	Good	Poor	Toplam
Fair	1	2	0	3
Good	1	14	0	15
Poor	0	4	0	4
Toplam tahmin	2	20	0	22




Şekil 2. Confusion Matrix: DeepEmbryo V2.1

8.4 Ek Grafikler: Learning Curve ve Sınıf Performansı

results klasöründeki per_class_performance.png, sınıf bazlı F1-score dağılımını hızlı okumak için kullanılmalıdır. learning_curve.png dosyası ise değerlendirme script'inde örnek verimliliğini göstermek amacıyla oluşturulmuş trend grafiğidir.



Şekil 3. F1-skor sınıflara göre dağılımı




Şekil 4 . Learning curve / sample efficiency grafiği

8.5 XAI: Grad-CAM Çıktıları

Grad-CAM analizi, modelin karar verirken görüntünün hangi bölgelerine ağırlık verdiğini gösterir. evaluate_model.py içinde conv5_block3_out katmanını hedeflenmiş, her sınıftan seçilen örneklerde orijinal görüntü, ısı haritası ve overlay yan yana üretilmiştir. xai_pipeline.py tarafındaki örnek rapor ise 20 Grad-CAM örneği için morfolojik odak yorumları üretmiştir.

Tablo 17. XAI çıktı envanteri

XAI çıktısı	Dosya	Raporda kullanım
Grad-CAM grid	results/gradcam_results.png	Modelin ICM/TE bölgelerine odaklandığını açıklamak
Tekil Grad-CAM örnekleri	xai_results/gradcam_samples/*.png	Başarılı ve düşük güvenli örnekleri göstermek
XAI metin özeti	xai_results/xai_summary_report.md	Güven skorları ve morfolojik odak cümleleri



Şekil 5 . Grad-CAM sonuçları

9. Uygulama, Raporlama ve Veritabanı

DeepEmbryo_App klasörü, modeli gerçek kullanıcı akışına taşıyan PyQt5 masaüstü uygulamasıdır. main.py model seçimi ve uygulama başlatmayı; model_loader.py PyTorch ve TensorFlow modellerini tek ModelWrapper arayüzüyle yüklemeyi; ui_main.py tekli analiz, toplu analiz ve geçmiş ekranlarını; ui_report.py PDF rapor üretimini; database.py ise SQLite tahmin geçmişini yönetir.

Tablo 18. Uygulama modülleri ve görevleri

Modül	Görev	Öne çıkan özellik
main.py	Uygulama girişi ve model seçimi	.pth, .pt, .h5, .keras otomatik/manuel seçim
model_loader.py	Model yükleme ve tahmin	PyTorch/TensorFlow ModelWrapper, softmax güven skoru
grad_cam.py / grad_cam_tf.py	XAI üretimi	PyTorch ve TensorFlow için Grad-CAM overlay
ui_main.py	Kullanıcı arayüzü	Tekli analiz, batch analiz, geçmiş sekmesi, uzman kararı alanı
ui_report.py	PDF rapor	Tahmin tablosu, olasılıklar, Grad-CAM, Gardner referansı
database.py	SQLite kayıt	predictions tablosu, ground_truth ve notes alanları


9.1 Veritabanı Durumu

deepembryo_history.db içindeki predictions tablosunda bu inceleme sırasında 350 kayıt bulundu. Tabloda timestamp, filename, filepath, predicted_class, class_id, confidence, is_low_confidence, notes ve ground_truth alanları yer alır. Bu yapı sürekli öğrenme döngüsü için önemlidir: uzman kararı daha sonra model yeniden eğitimi için etiketli veri olarak kullanılabilir.

9.2 Uygulama Ekran Görüntüleri



Şekil 6. Uygulama model seçimi ekranı



Şekil 7. Tekli analiz ekranı

DeepEmbryo

5. Gün Embriyo Kalite Değerlendirme Sistemi

Analiz Tarihi: 28.04.2026 20:38

Görüntü Dosyası: 3AA (3).bmp

Tahmin Sonuçları


Tahmin Edilen Sınıf	Güven Skoru	Durum
Good	%95.2	☐ Güvenilir

Sınıf	Olasılık
Good	%95.2
Fair	%0.4
Poor	%4.4

☒ Tahmin yüksek güvenilirlik ile yapılmıştır.

Görüntü Analizi ve Grad-CAM Görselleştirmesi

Sol: Orijinal embriyo görüntüsü | Sağ: Grad-CAM ısı haritası (Kırmızı bölgeler = Modelin en çok dikkat ettiği alanlar)



Morfolojik Özellik Raporu (Grad-CAM Analizi)

Model, embriyonun alt kenar (olası TE / dış halka bölgesi) bölgesine odaklandı.

Ortalama dikkat yoğunluğu: %9.4

ICM tipik olarak bir kenarda yoğunlaşmış hücre kütlesi,

TE ise embriyonun dış halkasını oluşturan hücre tabakasıdır.

Şekil 8. PDF rapor çıktısı

DeepEmbryo 5. Gün Blastosist Kalite Değerlendirme Sistemi | ResNet-50 + Grad-CAM Modeli Değiştir

Tekli Analiz **Toplu İşlem (Batch)** Geçmiş

Klasör Seç **Toplu Analizi Başlat** CSV Dışa Aktar C:/Users/ayyca/OneDrive/Masaüstü/EMBRIO DATASET/EMBRIO GRADE DATASET/3AA

	Dosya Adı	Tahmin Sınıfı	Güven (%)	Sınıf ID	Uyarı
1	3AA (10).bmp	Good	%81.0	0	✓
2	3AA (11).bmp	Good	%77.6	0	✓
3	3AA (12).bmp	Good	%84.4	0	✓
4	3AA (13).bmp	Good	%72.7	0	✓
5	3AA (14).bmp	Good	%63.9	0	▲ Düşük
6	3AA (15).bmp	Fair	%67.8	1	▲ Düşük
7	3AA (16).bmp	Good	%82.4	0	✓
8	3AA (17).bmp	Good	%63.3	0	▲ Düşük
9	3AA (18).bmp	Good	%52.0	0	▲ Düşük
10	3AA (19).bmp	Good	%71.9	0	✓
11	3AA (2).bmp	Fair	%64.7	1	▲ Düşük
12	3AA (20).bmp	Good	%52.0	0	▲ Düşük
13	3AA (21).bmp	Good	%50.7	0	▲ Düşük
14	3AA (22).bmp	Good	%58.7	0	▲ Düşük

40 görüntü işlendi. Düşük güven: 19 adet.

Şekil 9. Toplu analiz tablosu

DeepEmbryo 5. Gün Blastosist Kalite Değerlendirme Sistemi | ResNet-50 + Grad-CAM Modeli Değiştir

Tekli Analiz **Toplu İşlem (Batch)** Geçmiş

Yenile Tümüü Temizle Toplam 300 kayıt

	ID	Tarih/Saat	Dosya Adı	Tahmin	Güven (%)	Uyarı	Gerçek Sonuç
151	197	2026-04-27 19:58:06	4AA (16).bmp	Good	%69.0	▲ Düşük	—
152	196	2026-04-27 19:58:06	4AA (15).bmp	Good	%88.3	✓	—
153	195	2026-04-27 19:58:05	4AA (14).bmp	Good	%85.6	✓	—
154	194	2026-04-27 19:58:05	4AA (13).bmp	Good	%84.3	✓	—
155	193	2026-04-27 19:58:05	4AA (12).bmp	Good	%80.0	✓	—
156	192	2026-04-27 19:58:05	4AA (11).bmp	Good	%71.4	✓	—
157	191	2026-04-27 19:58:05	4AA (10).bmp	Good	%84.5	✓	—
158	190	2026-04-27 19:55:25	3BA.bmp	Good	%57.3	▲ Düşük	—
159	189	2026-04-27 19:55:25	3BA (6).bmp	Good	%93.8	✓	—
160	188	2026-04-27 19:55:25	3BA (5).bmp	Good	%86.6	✓	—
161	187	2026-04-27 19:55:25	3BA (4).bmp	Good	%63.8	▲ Düşük	—
162	186	2026-04-27 19:55:24	3BA (3).bmp	Good	%79.0	✓	—
163	185	2026-04-27 19:55:24	3BA (2).bmp	Good	%53.3	▲ Düşük	—
164	184	2026-04-27 19:55:24	3AB.bmp	Good	%67.7	▲ Düşük	—

Şekil 10. Geçmiş ve Ground Truth ekranı

10. Kritik Bulgular ve İyileştirme Önerileri

Tablo 19. Kritik teknik bulgular ve aksiyon önerileri

Bulgu	Etki	Öneri
Veri seti çok küçük	Derin modelin genellemesi sınırlı	Her sınıf için dengeli yeni embriyo görüntüsü toplanmalı
Good sınıfı baskın	Model Good tahminine kayıyor	Poor/Fair oversampling + sınıf ağırlığı + hedefli veri toplama
Poor recall sıfır	Klinik güvenlik açısından en kritik risk	Poor örnek sayısı artırılmadan klinik kullanım iddiası yapılmamalı
Learning curve simüle	Gerçek örnek verimliliği ölçümü sınırlı	Her veri oranında gerçek yeniden eğitim yapılmalı
Uygulamada sınıf eşleşmesi riski	Fair/Good etiketi ters görünebilir	CLASS_NAMES_KERAS sırası eğitim class_indices ile eşitlenmeli
Uygulama TF normalizasyon farkı	Notebook ve uygulama tahminleri ayrışabilir	Uygulama preprocessing eğitimdeki rescale hattına çekilmeli
XAI güvenleri düşük görünüyor	Birçok Grad-CAM örneğinde güven %40-%56 bandında	Calibration, temperature scaling ve daha fazla veri önerilir

Sonuç olarak DeepEmbryo, ders projesi ve prototip düzeyi için gerekli teknik ve analiz çıktılarını üretmiştir: eğitim logları, accuracy-loss grafikleri, confusion matrix, precision/recall raporu, Grad-CAM/SHAP çıktıları, masaüstü uygulama, PDF rapor ve SQLite geçmiş veritabanı mevcuttur. Ancak klinik kullanım iddiası için veri miktarı, Poor sınıfı başarımları, sınıf sırası tutarlılığı ve preprocessing tutarlılığı mutlaka iyileştirilmelidir.

11.Kaynakça

- [1] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- [2] Gardner, D. K., Schoolcraft, W. B., Wagley, L., Schlenker, T., Stevens, J., & Hesla, J. (1998). A prospective randomized trial of blastocyst culture and transfer in in-vitro fertilization. *Human Reproduction*, 13(12), 3434–3440. <https://doi.org/10.1093/humrep/13.12.3434>
- [3] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618–626. <https://doi.org/10.1109/ICCV.2017.74>
- [4] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988. <https://doi.org/10.1109/ICCV.2017.324>
- [5] Lukyanenko, R., Christiansen, E., Ma, S., Guo, L., Benedek, G., & Khrapko, K. (2021). Deep learning for non-invasive assessment of embryo viability using time-lapse images. *Scientific Reports*, 11, 16924. <https://doi.org/10.1038/s41598-021-95930-z>
- [6] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774. <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- [7] Lozza-Fiacco, S., Munné, S., & Meseguer, M. (2023). Artificial intelligence in the IVF laboratory: Overview through the cycle. *Fertility and Sterility*, 120(3), 443–452. <https://doi.org/10.1016/j.fertnstert.2023.06.015>
- [8] Chen, T., Guo, J., Zhao, J., Xu, C., Wang, H., & Chen, Q. (2022). DLT-Embryo: Dual local transformer for human embryo stage classification. *Biomedical Signal Processing and Control*, 78, 103907. <https://doi.org/10.1016/j.bspc.2022.103907>
- [9] TensorFlow Developers. (2024). *TensorFlow* (v2.13). Zenodo. <https://doi.org/10.5281/zenodo.4724125>